

Taller 2 de Cálculo Científico:

Análisis de Componentes Principales (PCA) e Identificación de Ancestría Genética

Fecha de entrega: 06/06/2026

Semestre 2026-I

1. Introducción

El estudio de la variabilidad genética humana se basa en identificar cambios mínimos en la secuencia del ADN denominados SNPs (*Single Nucleotide Polymorphisms*). Debido a la alta dimensionalidad de estos datos (donde el número de sitios genéticos suele superar por órdenes de magnitud al número de individuos), el Análisis de Componentes Principales (PCA) es la herramienta estándar para visualizar la estructura poblacional y detectar procesos de mezcla migratoria.

En este proyecto, implementaremos el flujo de cálculo numérico necesario para transformar datos crudos de genotipos en un mapa de ancestría utilizando la Descomposición en Valores Singulares (SVD).

2. El Conjunto de Datos (Input)

Se suministrará un archivo `datos_genotipo.csv` que contiene una matriz $\mathbf{G} \in \mathbb{R}^{n \times m}$ con $n = 30$ individuos y $m = 100$ SNPs.

2.1. Interpretación de los valores (0, 1, 2)

Dado que los seres humanos poseemos dos copias de cada cromosoma (organismos diploides), en cada posición evaluada existen dos alelos. Si definimos el alelo A como la variante de referencia y el alelo a como la variante mutada, los valores en la matriz se codifican así:

- **0 (Homocigoto Referencia):** Genotipo AA . El individuo no posee la variante.
- **1 (Heterocigoto):** Genotipo Aa . El individuo posee una copia de la variante.
- **2 (Homocigoto Variante):** Genotipo aa . El individuo posee ambas copias de la variante.

3. Procedimiento Algorítmico

3.1. 1. Estimación de Frecuencias y Limpieza

Para cada SNP j (columna), calcule la frecuencia del alelo variante p_j :

$$p_j = \frac{\sum_{i=1}^n G_{i,j}}{2n}$$

Nota: Si un SNP es constante ($p_j = 0$ o $p_j = 1$), dicha columna debe descartarse para evitar singularidades matemáticas en el siguiente paso.

3.2. 2. Normalización de Patterson (Wright-Fisher)

Para que cada sitio genético contribuya equitativamente a la varianza, transforme $\mathbf{G}$ en una matriz normalizada $\tilde{\mathbf{G}}$ mediante:

$$\tilde{G}_{i,j} = \frac{G_{i,j} - 2p_j}{\sqrt{2p_j(1 - p_j)}}$$

3.3. 3. Factorización y Proyección

Calcule la SVD de la matriz normalizada: $\tilde{\mathbf{G}} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$. Las coordenadas de los individuos en el espacio de las componentes principales se obtienen mediante:

$$\mathbf{PC} = \mathbf{U}\mathbf{\Sigma}$$

4. Nota para Físicos: Perspectiva de Sistemas Complejos

La matriz $\mathbf{K} = \frac{1}{m}\tilde{\mathbf{G}}\tilde{\mathbf{G}}^T$ es análoga a una matriz de correlación o parentesco. En física estadística, los autovectores de $\mathbf{K}$ representan los **modos de variación dominantes** del sistema. Los valores singulares σ_i indican cuánta “energía” (varianza genética) captura cada modo. El PCA permite separar la señal biológica del ruido estocástico (deriva genética).

5. Tareas y Entregables

Se debe entregar un informe en PDF (preferiblemente en L^AT_EX) y el código fuente (**Python**) que realice lo siguiente:

1. **Gráfico de Dispersión:** Visualice PC_1 vs PC_2 . Cada punto representa un individuo.
2. **Análisis de Mezcla:** Si observa individuos situados entre dos grupos claros, explique qué significa esto en términos de su historia genética.

5.1. Información adicional

1. El código fuente deberá estar documentado y debe permitir reproducir los experimentos.
2. La entrega será en grupos de máximo 2 personas.
3. Habrá interrogatorio.
4. Los proyectos deberán enviarse antes de las 11:59 pm al correo: calculo.cientifico.aux@gmail.com

6. Referencias Sugeridas

- Patterson, N., Price, A. L., & Reich, D. (2006). *Population Structure and Eigenanalysis*. PLoS Genetics.
- Trefethen, L. N., & Bau III, D. (1997). *Numerical Linear Algebra*. SIAM.

LMHR+Gemini/lmhr